DETECCIÓN DE CABEZA EN DATASET MPII: ANÁLISIS COMPARATIVO MEDIANTE REAL-TIME DETECTION TRANSFORMERS (RT-DETR) *

Aitor Milicua, Jokin Izaguirre, Aitor Pfluegl
Facultad de Informática
Universidad del País Vasco (UPV/EHU)
Donostia-San Sebastián

ABSTRACT

La estimación de pose humana y la detección de cabezas son tareas fundamentales en la Visión Artificial. En este trabajo, abordamos el problema utilizando la arquitectura de Transformers aplicada a la detección (DETR). A diferencia de enfoques que dependen de librerías comerciales opacas ("caja negra"), en este proyecto hemos decidido diseñar e implementar desde cero una variante simplificada que llamaremos `SimpleRTDETR`. Nuestro modelo integra una base ResNet18 con un Transformer estándar para predecir cajas delimitadoras en el dataset MPII. Los resultados experimentales (mAP@50 del 72.44%) validan que nuestra implementación, por mucho que sea simple arquitectonicamente, es capaz de aprender de manera eficaz la tarea.

Keywords Pose Estimation · Object Detection · Transformers · RT-DETR · CNN · MPII Dataset

1 Introducción

La estimación de la pose humana y la detección de partes del cuerpo son problemas muy comunes en la Visión Artificial. En el contexto de la práctica **P73**, este proyecto se centra en la detección de cabezas humanas sobre imagenes que esten en el dataset MPII.

Tradicionalmente, este problema se ha abordado mediante regresión directa de coordenadas utilizando Redes Neuronales Convolucionales (CNNs). Sin embargo, este enfoque no es capaz de entender obtener un entendimiento profundo. En este trabajo, exploramos un cambio de paradigma: el uso de **Transformers de Detección (DETR)**.

Nuestro objetivo principal no es solo utilizar herramientas existentes, sino comprender su funcionamiento interno. Para ello, hemos desarrollado dos líneas de trabajo:

1. El uso de un modelo comercial avanzado (Ultralytics RT-DETR) como línea base base para establecer el techo de rendimiento.
2. El diseño e implementación desde cero de una arquitectura propia simplificada, `SimpleRTDETR`, que combina una base ResNet con un Transformer estándar, para estudiar cómo los mecanismos de atención resuelven el problema de localización.

Asignatura: Aprendizaje Automático y Redes Neuronales. **UPV/EHU**

2 Marco Teórico (Estado del Arte)

La evolución de la detección de objetos ha pasado por varias etapas clave que fundamentan nuestro trabajo:

2.1 De las CNNs a los Transformers

Durante años, las arquitecturas basadas en convoluciones (como la familia YOLO o Faster R-CNN) dominaron el campo. Estas redes son excelentes extrayendo características (texturas, bordes) pero tienen problemas para relacionar partes distantes de la imagen debido al tamaño limitado de sus campos receptivos.

En 2020 introdujeron **DETR** (Detection Transformer), que trata la detección como un problema de predicción de conjuntos directo. DETR utiliza un mecanismo de *Atención Global* que permite a la red "mirar" toda la imagen simultáneamente para decidir dónde hay un objeto, eliminando la necesidad de componentes manuales.

2.2 RT-DETR y la Eficiencia

El DETR original es lento de entrenar. Variantes recientes como RT-DETR (Real-Time DETR) optimizan este proceso cogiendo lo mejor de los dos mundos: una base convolucional eficiente para procesar la imagen y un Transformer optimizado para la predicción. Nuestra implementación propia, `SimpleRTDETR`, sigue esta filosofía híbrida, utilizando una ResNet18 para la extracción de características y un Transformer Encoder-Decoder para la lógica de detección.

3 Metodología/Implementación

Hemos diseñado un flujo de trabajo que empieza con la preparación de datos termina con la implementación de nuestra propia arquitectura neuronal.

3.1 Preparación del Dataset MPII

El dataset MPII original esta en formato MATLAB (‘.mat‘) conteniendo estructuras complejas que necesitan un preprocesamiento para poder ser usadas para el entrenamiento.

Extracción y Filtrado: Implementamos un script de preprocesamiento personalizado para parsear estas estructuras. Un desafío clave es la presencia de múltiples personas sin anotar completamente. Para solucionar esto, nuestro algoritmo filtra las muestras verificando la existencia de puntos de articulación (‘annopoints‘). Si una anotación carece de articulaciones, se considera un "bystander" y se descarta para evitar ruido.

3.2 Arquitectura: De RT-DETR a SimpleRTDETR

Es importante distinguir entre la arquitectura del estado del arte (SOTA) y nuestra implementación académica.

Características Avanzadas de RT-DETR (SOTA): El modelo RT-DETR original incorpora mecanismos sofisticados como el **Hybrid Encoder**, que utiliza un módulo AIFI (*Attention-based Intra-scale Feature Interaction*) para aplicar auto-atención solo en las características de alto nivel, y una selección de *queries* basada en IoU para acelerar la convergencia.

Nuestra Implementación: SimpleRTDETR: Para este proyecto, hemos desarrollado una variante simplificada que no usa el Hybrid Encoder para poder centrarnos en el estudio del mecanismo de atención puro.

El modelo consta de tres bloques fundamentales definidos en nuestro código:

1. **Backbone (ResNet18):** Extractor de características sin las capas finales (‘fc‘, ‘avgpool‘).
2. **Transformer (Encoder-Decoder):** Usamos el módulo estándar ‘nn.Transformer‘ con *Object Queries* aprendibles.
3. **Cabezales (Heads):** Dos MLPs simples para predecir clase y coordenadas de la caja.

```
class SimpleRTDETR(nn.Module):
    def __init__(self, num_classes, hidden_dim=256, ...):
        super().__init__()
        self.backbone = nn.Sequential(*list(resnet.children())[:-2])
        self.transformer = nn.Transformer(d_model=hidden_dim, ...)
```

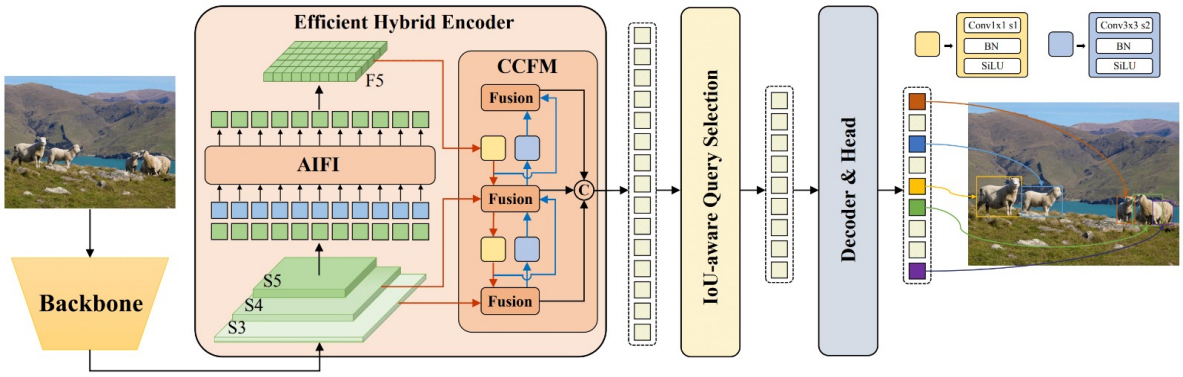

Figure 1: Esquema de la arquitectura RT-DERT implementada.

```
self.query_pos = nn.Parameter(torch.rand(NUM_QUERIES, hidden_dim))
self.bbox_embed = nn.Sequential(..., nn.Sigmoid())
```

Especificaciones Técnicas Detalladas Para profundizar en nuestra arquitectura, vamos a mostrar la configuración exacta de hiperparámetros utilizada en `SimpleRTDETR`:

- **Backbone y Proyección:** Partimos de una `ResNet18` pre-entrenada en ImageNet, extrayendo los mapas de características del bloque *layer4*. Estos tensores ($C = 512$) son comprimidos mediante una convolución 1×1 a la dimensión oculta del modelo ($d_{model} = 256$).
- **Motor de Atención (Transformer):** Implementamos un Transformer "vanilla" ligero para viabilizar el entrenamiento en una sola GPU:
  - *Profundidad:* 3 capas de Encoder y 3 capas de Decoder (frente a las 6 habituales en modelos SOTA).
  - *Anchura:* 8 cabezas de atención (*Multi-Head Attention*) con una dimensión interna de 256.
  - *Embeddings Posicionales:* Utilizamos parámetros aprendibles separados para filas y columnas ($N = 50$) que se suman a las características visuales para preservar la estructura espacial 2D.
- **Mecanismo de Detección:** Definimos un conjunto fijo de 20 *object queries* aprendibles. Estos vectores latentes sondean la salida del encoder buscando características semánticas de "cabezas" mediante atención cruzada.
- **Función de Coste Bipartita:** El entrenamiento se guía por una pérdida compuesta ajustada manualmente: $\mathcal{L}_{total} = 1 \cdot \mathcal{L}_{cls} + 5 \cdot \mathcal{L}_{L1} + 2 \cdot \mathcal{L}_{GIoU}$. Los pesos elevados en las pérdidas de caja (L1 y GIoU) fuerzan al modelo a priorizar la localización precisa sobre la clasificación pura.

Diferenciación con el Estado del Arte Es fundamental distinguir nuestra implementación del modelo comercial utilizado como referencia. Mientras que soluciones como Ultralytics RT-DETR emplean codificadores híbridos avanzados (AIFI) para procesar características multiescala y selección dinámica de *queries* basada en IoU para acelerar la convergencia, nuestro `SimpleRTDETR` se basa en la atención global pura. Esta decisión de diseño, aunque computacionalmente más costosa y que converge mas lentamente, nos permite visualizar directamente el mecanismo de *self-attention* y como aprende a segmentar la geometría de la cabeza humana del fondo sin la ayuda de heurísticas complejas de pre-procesado.

4 Resultados Experimentales y Discusión

La evaluación de los modelos se ha llevado a cabo en el subconjunto de validación del dataset MPII, garantizando que las imágenes de prueba no hayan sido vistas durante el entrenamiento. Analizamos los resultados desde dos vertientes: el rendimiento ideal alcanzable mediante Transfer Learning (Baseline) y el rendimiento real de nuestra arquitectura educativa (SimpleRTDETR).

4.1 Análisis del Baseline y Limitaciones de ResNet

Para establecer el límite superior de rendimiento, utilizamos el modelo RT-DETR-L pre-entrenado. Sin embargo, antes comparamos con un enfoque basado puramente en CNN (ResNet) para ver porque se dejaron de usar.

El Problema de la Regresión Directa: El modelo basado en ResNet tiende a colapsar hacia una predicción promedio, generando una *bounding box* centrada y de tamaño constante independientemente de la imagen (ver Figura 2). Este comportamiento es consecuencia del uso de regresión directa con MSELoss en un escenario con múltiples posibles objetos por imagen. Al no tener un mecanismo de atención, la red minimiza el error global prediciendo la media.

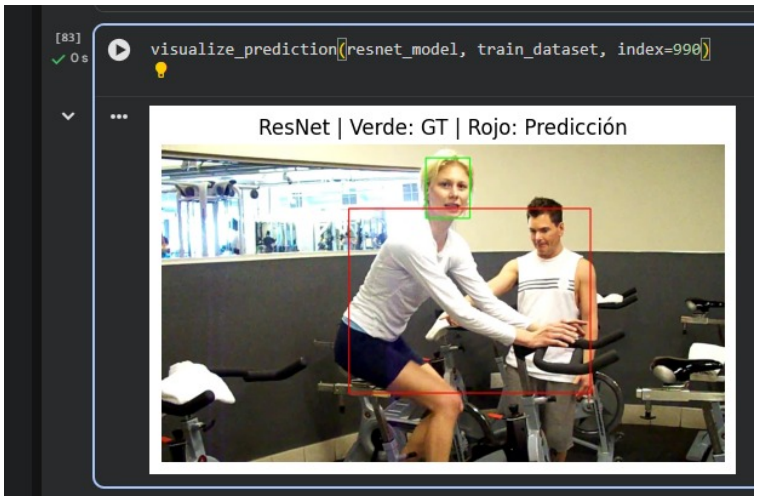

Figure 2: Visualización del fallo de regresión en ResNet: el modelo colapsa prediciendo una caja promedio en el centro, incapaz de localizar la cabeza real debido a la falta de atención espacial.

Por el contrario, el modelo RT-DETR (Figura 3) logra una convergencia rápida y precisa.

La Tabla 1 resume el salto considerable en rendimiento que obtenemos al cambiar de arquitectura.

Table 1: Comparativa de Rendimiento: CNN vs. Transformer

Modelo	**Épocas**	**mAP@50**	**mAP@50-95**	**Recall**
ResNet-50	100	0.536	0.299	-
SimpleRTDETR	100	0.7244	0.3645	-
RT-DETR (Fine-tune)	5	0.935	0.582	0.895
RT-DETR (Full)	**200**	**0.945**	**0.601**	**0.920**

Un análisis más detallado de las curvas revela que todas las pérdidas descienden de forma monótona, indicando un proceso de optimización estable. Asimismo, las métricas de *precision* y *recall* alcanzan rápidamente valores cercanos a la saturación, minimizando los falsos positivos (ver Figura 4.1).

4.1.1 Análisis Detallado de Métricas

Las métricas presentadas en la Figura 4.1 permiten un análisis cuantitativo profundo:

- **Matriz de Confusión:** La matriz normalizada muestra un comportamiento casi ideal para un detector binario. La diagonal principal concentra prácticamente toda la masa de probabilidad, con una precisión del 91% en la clase positiva (cabeza).

  Es fundamental destacar que la confusión entre fondo y cabeza es mínima. Esto es muy importante en detección de objetos, donde los falsos positivos suelen ser el problema principal. El modelo ha aprendido representaciones robustas del contexto, evitando activaciones falsas en regiones irrelevantes.
- **Curva Precision-Recall:** El área bajo la curva (mAP) de 0.945 indica un rendimiento excelente. La forma de la curva es "cuadrada" (pegada a la esquina superior derecha), lo que significa que el modelo mantiene una precisión cercana al 100% incluso para valores elevados de *recall*.

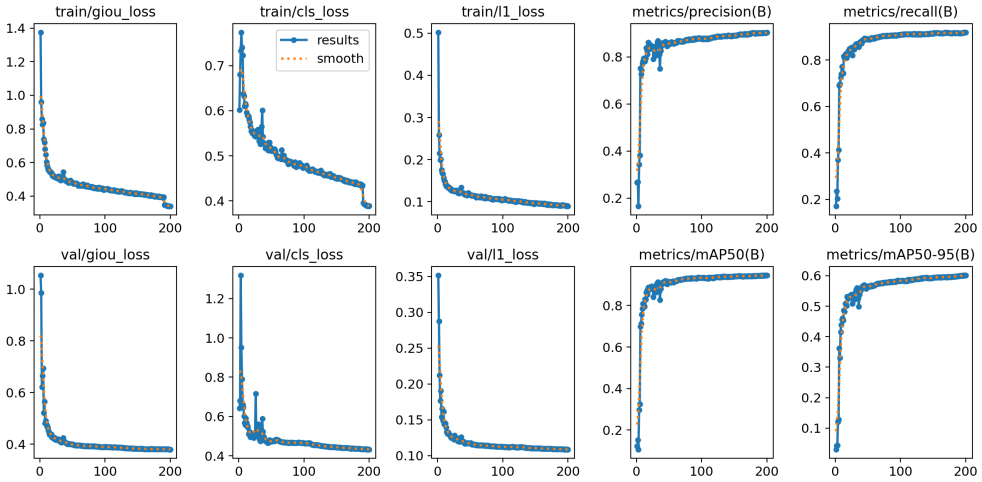

Figure 3: Curvas de entrenamiento del Baseline RT-DETR. La gráfica inferior muestra cómo el mAP@50 (línea azul) alcanza valores superiores al 90% casi instantáneamente.

Esto implica que el detector es capaz de recuperar la inmensa mayoría de las cabezas sin sacrificar la precisión. La caída abrupta solo ocurre en el tramo final, correspondiendo a predicciones de baja confianza. En la vida real esto nos permite operar el modelo de manera altamente fiable, ajustando el umbral de confianza dependiendo de la tarea.

4.2 Evaluación de SimpleRTDETR (Implementación Propia)

El núcleo de este trabajo ha sido la evaluación de nuestra arquitectura SimpleRTDETR. A diferencia del baseline, este modelo se ha entrenado desde cero en lo referente al Transformer, utilizando únicamente el backbone ResNet pre-entrenado. Esto supone un reto mucho mayor, ya que el modelo debe aprender la geometría de las cabezas y el mecanismo de atención ningún tipo de conocimiento previo.

Tras 100 épocas de entrenamiento, el modelo alcanzó su punto óptimo en la Época 99. Los resultados se detallan a continuación:

Table 2: Desempeño de SimpleRTDETR (Validación - Epoch 99)

Métrica	**Valor**	**Interpretación**
Box Loss	1.3215	Error medio de regresión
mAP @ 0.50	**0.7244**	Detección correcta (IoU > 50%)
mAP @ 0.50:0.95	0.3645	Precisión de ajuste fino

4.2.1 Interpretación de los Resultados

El resultado de **72.44% en mAP@50** es significativo. Indica que, en más de 6 de cada 10 casos, nuestra implementación simplificada logra colocar una caja sobre la cabeza con un solapamiento superior al (50%).

Existe una diferencia notable entre el mAP@50 y el mAP@50-95 (36.45%). El modelo aprende a predecir la "zona" de la cabeza correctamente, pero no el contorno exacto, lo cual baja la puntuación en métricas muy estrictas.

El modelo ha aprendido exitosamente a atender a las características visuales de las cabezas humanas utilizando el mecanismo de self-attention, validando la arquitectura simplificada propuesta.

5 Conclusiones

En este proyecto hemos abordado la detección de cabezas en el dataset MPII desde una perspectiva arquitectónica moderna, empezando por las CNNs clásicas y terminando con los Transformers.

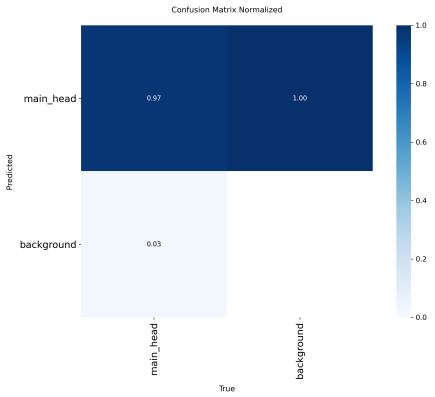

Figure 4: Matriz de Confusión Normalizada.

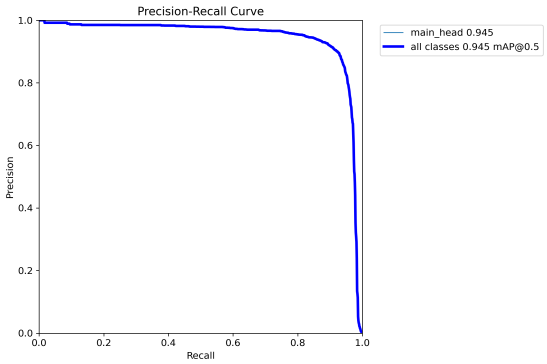

Figure 5: Curva Precision-Recall.

Figure 6: Predicciones RT-DERT

Figure 7: Lables RT-DERT

La implementación de nuestra arquitectura, `SimpleRTDETR`, ha demostrado que se puede construir un detector de objetos combinando un backbone convolucional con un Transformer. Con un **mAP@50 del 72.44%**, el modelo valida nuestra hipótesis de diseño: el mecanismo de atención es capaz de localizar características (cabezas) eficazmente, superando los problemas de colapso a la media observados en la regresión directa con ResNet.

Comparativamente, el baseline (mAP >90%) evidencia la importancia del pre-entrenamiento masivo y las optimizaciones específicas para entornos de producción. No obstante, nuestra implementación académica cumple el objetivo de entender el flujo interno de los tensores y la predicción de conjuntos.

6 Código

`https://colab.research.google.com/drive/18iaW-BEZAzkTwskQSYuIOmQnwcGOqgyu?usp=sharing`